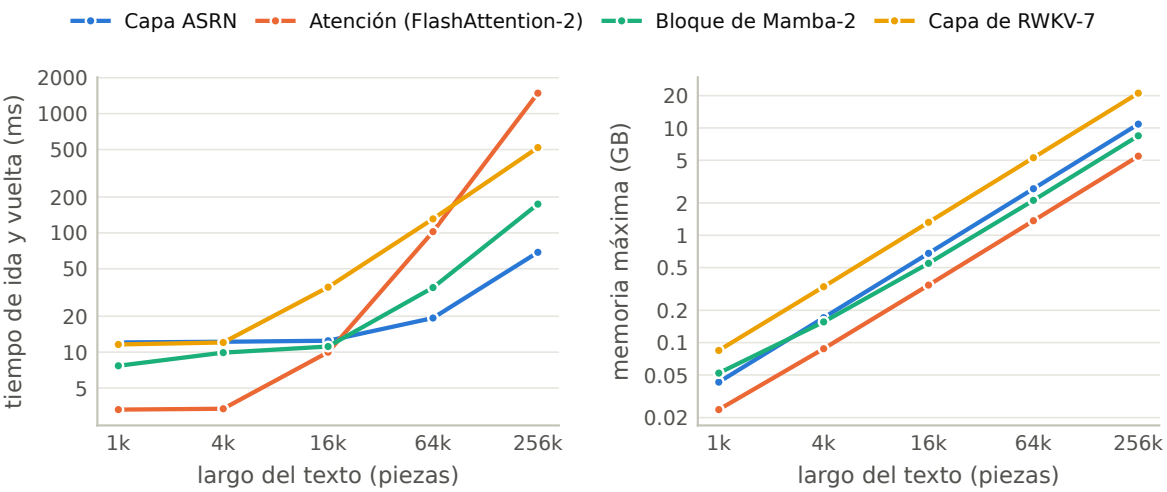
Capa ASRN
Atención (FlashAttention-2)
Bloque de Mamba-2
Capa de RWKV-7
tiempo de ida y vuelta (ms)
2000
1000
500
200
100
50
20
10
5
1k
4k
16k
64k
256k
largo del texto (piezas)
memoria máxima (GB)
20
10
5
2
1
0.5
0.2
0.1
0.05
0.02
1k
4k
16k
64k
256k
largo del texto (piezas)